

今天，赶什么梗？

B 站网络梗热度与生命周期分析系统

开场先问一句

「闪身步」9月21日才有人解说，如今热度76.8，全站第一；近7天头部播放1,670万。

从「有人把它讲明白」到「火到不能再拖」，中间只有5天。

这5天，就是这个课题要研究的东西。



今天，赶什么梗？

先把话说在前面：本阶段交付的是「一条跑通的真实数据链路 + 一套可复算的测量口径」，不是一堆已经成立的结论。

里面有一个我自己先立、后被数据推翻的实验（第11页）——我认为那才是这个课题最有价值的部分。

汇报人 _____

学号 _____


指导教师 _____

_____ 年 ____ 月 ____ 日

先测一下

这五个梗，认识三个以上的举手

不是我编的题——它们就是此刻 B 站真实热榜前五名。封面是真实视频封面，数字是库里现算的。



闪身步

热度 76.8 · 爆发期


爆发期 · 置信度 0.95



耍起

热度 67.2 · 上升期

上升期 · 还来得及



闹吃 vs 古振兴

热度 54.6 · 上升期

上升期 · 慎赶



野生狗奶

热度 47.5 · 上升期

双 UP 认证 · 慎赶



大狗叫

热度 47.0 · 数据不足

近 7 天只观测到几天

认不全太正常了：梗的活跃窗口一般就两三周。难受的地方不在这——你听说了、点开创作中心、脚本写完发出去，它已经不火了。

注意第 5 名「大狗叫」：热度 47.0 排进前十，但近 7 天真正观测到的天数太少，算法拒绝给阶段与赶梗结论，标成「数据不足」。宁可说不知道，也不编一个阶段。

三家人在问同一句话：现在做，还来得及吗

他们都缺同一个东西——不是排名，是刻度。

一个 3 万粉的 UP 主

他有手感，但没有刻度：同一个梗，他每次判断都不一样。

「这个梗我上周就刷到了，现在拍是不是凉了？」

品牌社媒运营

跟的是词，不是梗：词还挂在榜上，梗可能三天前就过气了。

「热搜上这个词，我们今晚要不要跟？」

我室友（也是目标用户）

因为他拿到的永远是排名，不是时间。

「为什么我每次知道一个梗，它都已经不好玩了？」

现有工具都能回答「此刻什么排在前面」，回答不了三个更值钱的问题——有多火（一个跨梗可比的数）、走到哪一段（在冲、在顶、还是在崩）、现在赶还来不及。

微博热搜与平台热榜是存量快照：一个梗崩盘当天照样挂在榜上；百度指数度量的是搜索词，不是梗——「松弛感」这类口语词会混进大量无关检索。

把「还赶不赶得上」拆成三个能被回答的问题

每个问题都对应一个已实现的算法模块；不能量化的一律不做。

RQ1

一个梗现在到底有多火？

- 输出 0-100 热度指数：五因子加权，绝对量先做对数区间归一化
- 同一个数可以横向比两个梗，也可以纵向比一个梗的两周
- 实现： `backend/app/analytics/hotness.py`

RQ2

它走到了生命周期的哪一段？

- 六个阶段：萌芽 / 上升 / 爆发 / 平稳 / 退潮 / 过气
- 只用四个可观测量判定：增长率、距峰值差、连续下滑天数、活跃度
- 实现： `backend/app/analytics/lifecycle.py`（规则自上而下匹配）

RQ3

现在赶还来得及吗？

- 三态输出：还来得及 / 慎赶 / 你来晚了，附带置信度与一句理由
- 由 RQ1 + RQ2 结果经判定规则导出，不是独立模型猜的
- 实现： `backend/app/analytics/catch_up.py`

明确不做的三件事，写在幻灯片上，也写在代码里：

- ① 不做未来数值预测，只描述已经发生的数据；
- ② 不让大模型修改任何事实或判定——它只能把算法结论翻译成成人话，越界表述（「预计」「一定会爆」）在服务层直接丢弃；
- ③ 不做多平台、不做用户体系，先把 B 站这一把尺子做准。

三条线各自都做到了，缺的是把它们接起来的那个人

不是没人研究，是没人把「梗」当成一个能跨创作者聚合、还能复算的时间序列对象。

模因与网络梗研究

做到了什么

定义、分类、生成机制、社会心态

代表工作

Dawkins 1976 · Shifman 2012/2013 · Bauckhage ICWSM 2011 · 谢朝群 2007 · 薛一飞 2024

留下的缺口

几乎不给出可复算的时间度量

注意力与话题生命周期

做到了什么

曲线形状可分类、半衰期在缩短、阶段可划分

代表工作

Downs 1972 · Crane & Sornette PNAS 2008 · Kleinberg KDD 2002 · Yang & Leskovec WSDM 2011 · Lorenz-Spreen 2019

留下的缺口

对象是新闻 / 议题 / 搜索词，不是「梗」

流行度量化与预测

做到了什么

早期增速可预测、热度寿命可建模

代表工作

Szabo & Huberman CACM 2010 · Tan BMSB 2014 · Li 2016 · Xu CIKM 2025

留下的缺口

落到单条内容，未做跨创作者的「梗」级聚合

本课题的位置：把三条线接成一条能跑起来的链路。

用两位解说 UP 主的真实投稿证明「这是个真梗」→ 用逐日头部内容抽样把它变成时间序列 → 用五因子指数与规则引擎给出热度、阶段与赶梗判断 → 把全部口径与数据新鲜度直接印在产品界面上。文献核验记录（DOI / CNKI）在 [docs/research/related-literature.md](#)。

可行性：不是设想

已可运行

这条链路已经跑通了，今天的数字都是它算出来的

先把「能不能做」回答掉，后面才轮得到「做得对不对」。



数据负责证明 · 算法负责判断 · 大模型负责解释 · 界面负责让人想看



数据可得性也验证过了，不是假设：WBI 签名后匿名可用的只有搜索与视频详情接口。

UP 主空间接口会被风控（-352 / 412），字幕轨与站内 AI 总结端点匿名一律拿不到（实测 code=0 但 subtitles 为空、总结接口直接 -101 未登录）。这两件事都如实写进了产品的「数据透明度」，没有拿旧证据凑数。

喂给算法的不是示例数据，是 5,044 条真实视频

下面每个数字都可以现查： `sqlite3 backend/data/gengv1.db "select count(*) from videos where data_source='bilibili'"`

5,044

真实 B 站视频

另有 108 条演示视频，来源字段分开、不混算

2,209

日粒度统计行

覆盖 2026-08-28 ~ 09-28，逐日不是聚合摊派

504

万字

近 30 天采样样本的头部播放合计（6.5 亿）

61

个梗有站内名次

1,150 条视频带 B 站综合排序名次，够两档排法用

0


条演示数据进榜

真实模式下未在线核验的梗一律不上榜

口径先说清楚，免得误读：

「当日播放量」= 那天该关键词下播放量最高的 20 条相关视频的合计，不是全站绝对量。跨日、跨梗用的是同一把尺子，所以形状与排序可信，绝对数值不能拿去跟站方数据对。

为什么逐日分开查：不带日期区间时，搜索结果会被最近发布的内容占满，早期日期根本查不到。第一版就是一次搜完再聚合，算出了 +23,616% 的假增长。



我把「两个 UP 主都做过」这个规矩废掉了

这是被真实数据打脸之后改的——而且打脸打得很干脆。

旧口径：取交集（两位都介绍过）

90 天滚动窗口实测：梗百科单独介绍 37 个，梗指南 22 个，交集只剩 8 个。

等于让日更账号的选题，被周更账号的排期一票否决。

当时热度最高的「闪身步」（当时 81.0）就在库外——它只在梗百科做过。

新口径：取并集（任一位介绍过即入池）

同一批投稿，入池从 8 个变成 51 个。

「双 UP 认证」降级为标签，而不是闸门：只有一位做过就写明是哪一位，可信度信息一点没丢。

认证窗口 90 天 ≠ 报告窗口 30 天：解说通常比爆发期早 1~2 周，两窗合一会把还在热的梗排除。

认证强度如实标在卡片上，而不是用来卡进不进库。

系统实时状态：verified_both（双 UP 核验）8 个 · partially_verified（单 UP 核验）38 个 · unverified 39 个。真实模式下最后一类不进热榜——演示梗的认证位是自己写上去的，不算证据。准入口径写在 models / services / api 三处并各有测试。

顺手记一个坑：UP 主为规避敏感词会把标题写成「XX 在哪？最优骑士小碎步」这类占位名。

实测 51 条里有 6 条。这类名字没法拿去检索，在抽取阶段直接丢弃，而不是让它进库当一条永远采不到数据的空壳。

0.25 给了增长，因为要回答的是「最近是不是在变热」

权重不散落在代码里：全部集中在 `backend/app/config/algorithms.py`，改数只改这一处。

$\text{Hotness} = 0.25 \cdot \text{增长} + 0.25 \cdot \text{播放} + 0.20 \cdot \text{互动} + 0.16 \cdot \text{内容} + 0.14 \cdot \text{创作者}$



对数区间归一化。播放量差三个量级的梗必须能同框比较；线性归一会让亿级老梗永远压住新梗。

增长只看最近 7 天 vs 前 7 天。去年 1 亿播放、今天没人做的梗，不该排在前面。

样本不足就不外推。前一周讨论量 < 30 或相关视频 < 3 条时，增长率置空并对整体打折，卡片显示「一」而不是 +585% 这种噪声。

门槛与算法分开。「准入」回答这是不是个真梗；「上榜」还要回答今天玩什么——过气不上榜，近 7 天头部播放 < 1 万不上榜。

四条约束合起来就是一句话：热度回答「最近是不是在变热」，而不是「历史上有多热」。

六个阶段是数出来的，不是感觉出来的

判定只用四个可观测量：增长率、距峰值差、连续下滑天数、活跃度。



第七个状态不是阶段，是闸门：「数据不足」。

近 7 天真正观测到的天数不足 4 天时，算法拒绝给阶段与赶梗结论，置信度记 0。热度照给（存量水平是横截面比较），但时间轴上的结论没有地基就不说。

当前真实分布（入池 71 个梗）

数据不足 33 · 退潮期 12 · 萌芽期 9 · 上升期 8 · 平稳期 5 · 过气 4 · 爆发期 1

最大的一格是「数据不足」，我没有把它藏起来。

赶梗三态由算法给出，大模型只能复述

还来得及 / 慎赶 / 你来晚了，各带置信度与一句理由。模型返回的 status 与算法不一致时以算法为准；文案里出现「预计」「未来 7 天」「一定会爆」这类预测口吻会被直接丢弃。

大模型不参与任何数值判断，也不做未来数值预测。

阶段划分的来路：Downs（1972）议题—注意力周期 · 宋宁、刘婵君（2016）舆情演化阶段 · Crane & Sornette（2008）在线注意力只有少数几种可复用的脉冲响应形状。

四个我自己踩出来的坑，每个都留了症状、诊断、处方

这一页是我认为整个课题最有数据科学含量的部分——上游接口是测不准的，观测得自己造。

症状	实测现象	诊断	处方
假增长	一次抓完再摊到每天，算出 +23,616%	拿今天看到的累计播放量回填了历史某天	逐日带 pubtime_begin/end 区间查询，只统计当天发布内容
抽样抖动	同一个词同一天两次：一次 20 条、一次 0 条	琵琶曲从 4 天 / 3,976 万被刷成 1 天 / 18 条，热度 44.2 → 0.0	同一天只保留更好的一次观测（比样本数与播放量，绝不相加），并提供快照回填工具
空窗误删	一次采空就把历史真实数据清掉	把「没看见」当成「没有」	空窗只清非同源数据，同源旧快照保留并计数；没拿到就写 observed=0
短别名污染	「我不是黄豆」的别名「黄豆」命中即算相关	418 条样本里 343 条其实只在讲黄豆，该梗还挂着榜首	短于 4 字的别名只算弱证据，必须再有第二个词佐证


顺带一个反直觉的实测：B 站匿名搜索对同一个词、同一天会随机返回空结果——逐日打 15 天 × 2 次，30 次里只有 12 次拿到内容。所以「没观测到」和「当天没人做」在库里必须长得不一样。重试后覆盖度从 40% 提到 87%；当前全库平均观测覆盖度 55.4%。

我先立了一个判据，然后拿 31 个真实样本把它推翻了

如果一页 PPT 只能留一页，我留这页。

被检验的假设（也是我一开始的想法）

「解说视频播放量破百万的梗，才值得花成本去做。」



解说播放量衡量的是那个账号自己的粉丝盘，而且是发布那一刻的存量——不是梗的热度。

这件事教会我一件事：先立一个能被数据推翻的判据，再去检验它。被推翻不丢人，拿一个没检验过的直觉当设计依据才丢人。

检验结果

Pearson $r = +0.40$ ($p = 0.028$)

Spearman $\rho = +0.29$ ($p = 0.12$ ，不显著)

$R^2 \approx 0.16$ ， $n = 31$

结论：解说播放量只能解释热度方差的约 16%。

反例同时存在，而且方向完全相反：

- 「闪身步」解说 64.6 万 → 该梗热度 76.8，全站第一
- 「宗主第二招」解说 160.7 万 → 该梗热度 0.0

所以这个指标可以用来做采集成本的预算筛，不能当准入判据。

三件事我做得跟别人不一样

不是「用了什么新技术」，是「换了什么研究对象、换了什么口径、多给了什么输出」。

01

对象创新

把「梗」从单条内容，提升成跨创作者聚合的时间序列实体。

- 一条视频的热度是它的播放量；一个梗的热度要跨几十上百条视频聚合
- 聚合之后才谈得上「它现在走到哪一段」——单条内容没有生命周期，只有发布曲线

02

准入创新

用两位解说 UP 主的真实投稿作存在性证明，并集准入 + 认证降级为标签。

- 覆盖率提升 6.4 倍（交集 8 → 并集 51），可审计性没损失：每条证据都是真 BV 号
- 「双 UP 认证」从闸门变成卡片上的可信度标签，信息不丢、门槛不误杀

03

输出创新

不止报热度，还给带置信度的赶梗时机判断，并把口径印在产品上。

- 抽样口径、统计滞后、认证强度、观测覆盖度，全部显示在界面上，可被质疑与复算
- 算法定状态、大模型只翻译——AI 是单点故障时，产品闭环不会断

还有一件不算创新、但我认为同样重要的事：把「不知道」做成一个合法输出。

我知道它哪里不准，而且写下来了

主动交代局限不是减分项——藏着才会在答辩现场被拆。

脉冲型梗会被误判

琵琶曲 30 天只有 4 天有内容，却播了 3,976 万，规则容易判成过气

→ 上榜层已用「近 7 天头部播放下限」兜底；后续为脉冲型单独建模

残值会被误判成萌芽

「omg 你吓到了我」近 7 天只剩 3,770 次播放，却落在萌芽期

→ 给萌芽期补最低活跃度约束（已列入下一步）

上游接口受风控

匿名只能稳定取到账号最近约 150~400 条投稿，深翻页被 -352 / 412 挡住

→ 退避重试 + 索引缓存 + 缺口如实报告；可选 Cookie 增强核验

抽样口径的天花板

当日头部 20 条合计，不是全站绝对量；一个全靠小爆款堆起来的梗会被低估

→ 界面与论文都写明口径；计划做 20 → 10 / 50 的敏感性分析

已知未修的口径偏差

view 是「该日发布 cohort 的累计播放」，老日子多攒了十几天，序列天生向今天下坡

→ 年龄中性的替代量是 search_total；改这个要重排全部榜单，先修可信度、暂不动公式

伦理与合规：只取公开元数据（标题、播放、点赞、弹幕数、封面链接），不登录、不绕登录墙、不存用户隐私；图片引用外链而非转存，频控单梗一轮约 30 次查询。

接下来六周，每周都有一个能被检查的交付物

不写「继续完善」这种话——每一周都能问「东西在哪」。

第 1-2 周

口径收尾

- 脉冲型梗单独建模
- 萌芽期补最低活跃度约束
- 上榜层回归测试

第 3 周

数据与调度

- 增量刷新 + 系统计划任务
- 17 个采空梗用别名兜底再采一轮
- 每日自动更新的数据集

第 4 周

用户实验

- 20 人对照：看热搜 vs 看本系统
- 选题准确率 + 主观有用性
- 实验数据与分析

第 5 周

一致性检验

- 阶段判定混淆矩阵
- 热度与人工标注的 Spearman 相关
- 门槛消融实验

第 6 周

成稿

- 论文撰写
- 代码与可复现说明
- 数据集整理

第 4、5 周这两块，是把「我觉得准」换成「我能证明它准」的关键。

诚实说明当前状态：用户实验、混淆矩阵、权重消融、门槛消融这四项都还没跑，所以本阶段我给不出「系统有多准」的结论，只能给出「系统是怎么算的」。这也是开题该有的样子——如果现在什么都做完了，开题就没有意义了。

准备被问的

我猜您会问这四个问题

Q 数据是抓的，接口一抖结论不就变了？

A 这正是我踩坑最多的地方：逐日区间查询解决假增长、同日取更优观测解决抽样抖动、observed 标记解决空窗、弱别名规则解决污染。四条都在第 11 页。

Q 每天只取头部 20 条，能代表真实热度吗？

A 不能代表全站绝对量，但足以支撑跨梗跨日的可比排序。代价我承认：一个全靠小爆款堆起来的梗会被低估，论文里会做 $20 \rightarrow 10 / 50$ 的敏感性分析。

Q 权重 0.25/0.25/0.20/0.16/0.14 会不会太主观？

A 初始权重来自设计判断。约束它的是两件事：对数区间归一化让量级不吃掉权重；样本不足时不外推。权重消融与人工标注一致性检验列在第 15 周计划里。

Q 大模型在里面做什么？它胡说怎么办？

A 只把算法已经定好的结论翻译成成人话。返回的 status 与算法不一致时以算法为准，出现「预计」「未来 7 天」这类预测口吻直接丢弃；没 Key 时退回算法文案，闭环不断。

提前把答案写在纸上，比现场现编一个数字安全得多。