

梗会凉，账要算清

赶梗潮：B 站网络梗热度与生命周期分析

一句话结论

「梗」可以做成一个可复算的时间序列对象：85 条记录 → 35 个通过核验 → 20 个上榜，每一步的丢人原因都能列出来。

而最有价值的部分，是我用真实数据推翻了自己的一个判据（第 9 页）。



今天，赶什么梗？

这份答辩分三段：先给能证明的，再给还没做完的，最后给不打算做的。

还没做完的（混淆矩阵、权重消融、用户实验）在第 10 页，画成了空白面板，我不会拿它们冒充结果。

汇报人 _____

学 号 _____

指导教师 _____

_____ 年 ____ 月 ____ 日

三个数说清这个系统今天算出了什么

三个数不是同一个东西的三次说法——它们是三层口径收紧之后的结果。

20

个梗上了热榜

从 85 条记录里筛出来的最终结果

76.8

榜首热度（闪身步）

爆发期 · 还来得及 · 置信度 0.95

55.4%

平均观测覆盖度

近 7 天窗口里真正采到数据的天数占比

33

个梗被判「数据不足」

不是算不出来，是不肯硬算

当前热榜前 8（全部来自真实采集，可在库里逐条复核）

名次	梗	热度	阶段	赶梗判断	置信度	认证
1	闪身步	76.8	爆发期	还来得及	0.95	梗百科认证
2	耍起	67.2	上升期	还来得及	0.95	梗百科认证
3	闹吃 vs 古振兴	54.6	上升期	慎赶	0.81	梗百科认证
4	琵琶曲	50.3	数据不足	说不准	0.00	双 UP 认证
5	牛来	48.6	平稳期	慎赶	0.81	双 UP 认证
6	驾考宝典	48.5	退潮期	你来晚了	0.92	双 UP 认证
7	老叟戏顽童	48.2	退潮期	你来晚了	0.92	双 UP 认证
8	verity	48.2	退潮期	你来晚了	0.88	双 UP 认证

5,044 条真实视频、 2,209 行日统计，全部来自公开接口

没有一条是生成出来的：演示数据单独标注、单独存储、不进真实榜单。

5,044

真实 B 站视频

data_source='bilibili'

2,209

日粒度统计行

覆盖 2026-08-28 ~ 09-28

652,023,906

近 30 天头部播放合计


6.52 亿，按周发布 cohort 的累计口径

1,150

条视频带站内名次

61 个梗有 B 站综合排序名次

从 85 条记录到 20 个上榜：每一层都在丢人，且丢得有名有姓



三层口径，每层都在丢人

85 → 71：有梗但窗口内没采到内容，不装作有数据

71 → 35：来源必须是真实采集，且至少一位 UP 主的投稿里真抓到过证据


35 → 20：过气的 2 个 + 近 7 天头部播放不足 1 万的 13 个，被「活着」门槛挡掉

被挡掉的梗没有消失：梗库接口 scope=all 仍然返回，趋势和详情都能看，只是不进首页热榜。

目前 8 个双 UP 核验、38 个单 UP 核验、39 个未核验。最后一类不进热榜——演示梗的认证位是自己写上去的，不算证据。

热度不是播放量，是五个因子加权出来的

权重全部集中在一个文件里，不散落在代码各处，前端一行判定逻辑都不写。



四个刻意的设计决定

① 对数区间归一化

播放量差三个量级的梗必须能同框比较。线性归一会让亿级老梗永远压住新梗。

② 增长权重 = 播放权重 = 0.25

要回答的是「最近是不是在变热」。去年 1 亿播放、今天没人做的梗不该排前面。

③ 样本不足就不外推


前一周讨论量 < 30 或相关视频 < 3 条时增长率置空并对整体打折，显示「一」而不是 +585% 这种噪声。

④ 算法与文案分离

热度、阶段、赶梗判断全部由算法算出；大模型不参与任何数值判断。


六个阶段加一个闸门，判定只用四个可观测量

增长率 · 距峰值差 · 连续下滑天数 · 活跃度——规则自上而下匹配，每条结论都能指出依据。



最大的一格不在上排，在闸门里：「数据不足」33 个。

近 7 天观测到的天数不足 4 天时，算法拒绝给阶段与赶梗结论，置信度记 0。界面不把它画进生命轴线——它不是第七个阶段，是「没有地基所以不说」。



为什么这一格这么大

B 站匿名搜索对同一个词、同一天会随机返回空结果：实测逐日打 15 天 × 2 次，30 次里只有 12 次拿到内容。

不重试就会把序列打出一片 0，而「0」和「那天真没人做」在返回体里长得一样。


处理：每天额外重试 2 次（间隔递增）→ 覆盖度从 40% 提到 87%；拿不到就记 observed=0，绝不写 0 活动。

当前全库平均观测覆盖度 55.4%。

先给一个被推翻的结论

解说播放量高的梗，并不更热

这是我自己先立的判据，然后拿 31 个真实样本把它推翻了。



被检验的假设

「解说视频播放量破百万的梗，才值得花成本去做。」

检验结果 ($n = 31$)

Pearson $r = +0.40$ ($p = 0.028$)

Spearman $\rho = +0.29$ ($p = 0.12$ ，不显著)

$R^2 \approx 0.16$ ：解说播放量只能解释热度方差的约 16%。

两个方向相反的反例：

- 闪身步：解说 64.6 万 → 梗热度 76.8 (全站第一)
- 宗主第二招：解说 160.7 万 → 梗热度 0.0

结论：解说播放量衡量的是那个账号自己的粉丝盘，而且是发布时刻的存量。

它能用来做采集成本的预算筛，不能当准入判据——所以新口径用的是「两位 UP 主里至少一位介绍过」，而不是「播放量够高」。

四个坑，每个都留了症状、诊断、处方

上游接口是测不准的，稳定观测得自己造出来——这是我认为本课题最有数据科学含量的部分。

症状	实测现象	诊断	处方
假增长	一次抓完再摊到每天，算出 +23,616%	拿今天看到的累计播放量回填了历史某天	逐日带 pubtime_begin/end 区间查询，只统计当天发布内容
抽样抖动	同一个词同一天两次：一次 20 条、一次 0 条	琵琶曲从 4 天 / 3,976 万被刷成 1 天 / 18 条，热度 44.2 → 0.0	同一天只保留更好的一次观测（比样本数与播放量，绝不相加）
空窗误删	一次采空就把历史真实数据清掉	把「没看见」当成「没有」，空壳与真零在库里无法区分	空窗只清非同源数据；同源旧快照保留并计数，拿不到就记 observed=0
短别名污染	「我不是黄豆」的别名「黄豆」命中即算相关	418 条样本里 343 条其实只在讲黄豆（琵琶曲黄豆版、炒黄豆），该梗还挂着榜首	短于 4 字的别名只算弱证据，必须再有第二个词佐证才能过阈值

统一句式：症状 → 实测现象 → 诊断 → 处方。四条都能在 docs/data/refresh-report.md 与库里复查。

另外两个可复现的实测结论：匿名请求 player/wbi/v2 返回 code=0 但字幕轨为空数组；B 站图床带 Referer 会 403、不带才 200（所以前端 img 必须 no-referrer）。

三项做完了的验证，结论都写在这里

没做的三项在下一页，画成空白面板——这两页请不要混看。

① 判据证伪实验

- 假设：解说播放量破百万的梗才值得做
- 方法：对 31 个上榜梗做相关分析
- 结果：Pearson $r = +0.40$ ($p = 0.028$)；Spearman $\rho = +0.29$ ($p = 0.12$ ，不显著)； $R^2 \approx 0.16$
- 结论：判据被推翻，改用它做成本预算筛，不做准入门槛

② 观测策略的覆盖率提升

- 问题：同词同日匿名搜索会随机返回空结果（30 次里只有 12 次拿到内容）
- 方法：每天额外重试 2 次 + 同日取更优观测 + 快照回填
- 结果：单日覆盖度 40% → 87%；同日沿用更优观测 169 天
- 结论：把「没看见」和「没有」在数据模型里彻底分开

③ 门槛消融（规则层）

- 做法：逐层加上「过气不上榜」与「近 7 天播放 ≥ 1 万」两条门槛
- 结果：候选从 35 收敛到 20；挡掉的 15 个里 2 个过气、13 个只剩历史残值
- 反例检验：琵琶曲 30 天只有 4 天有内容却播了 3,976 万——刻意不用天数当门槛
- 结论：门槛用播放量下限而不是活跃天数，避免误杀脉冲型梗

这三项的共同点：都是先立一个可被数据推翻的说法，再去检验它。

这四块是空的，我不打算装作它们已经跑完

现场如果必须填，我会说「这是下一步」——不会现编数字。

待补实验

A • 阶段判定一致性（混淆矩阵）

- 标注方案：____ 个梗 × ____ 名标注者（待定）
- 指标：混淆矩阵 + 准确率 / Kappa = ____
- 对照：规则判定 vs 3 名标注者多数票

计划第 5 周完成

待补实验

B • 权重消融实验

- 做法：每次对一个权重 ± 0.05 ，重算排名
- 指标：排名 Spearman 相关 = ____
- 目的：证明 0.25/0.25/0.20/0.16/0.14 不是拍脑袋

计划第 5 周完成

待补实验

C • 用户实验（对照）

- 方案：____ 人对照「看热搜」vs「看本系统」
- 指标：选题准确率 = ____ / 主观有用性 = ____
- 待定：实验平台与任务设计

计划第 4 周完成

待补实验

D • 抽样口径敏感性分析

- 做法：把头部 20 条改成 10 / 50 重跑
- 指标：排名 Spearman 相关 = ____
- 目的：说明结论对样本量不敏感

计划第 5-6 周完成

为什么把它们画成空白面板：一份答辩如果什么都不缺，通常说明标准定得太低。

这四块分别对应用户实验、混淆矩阵、权重消融、抽样敏感性——也是评委最常问的四组数字。我先承认它们没有，再讲我打算怎么补。

不是「我做了个网站」，是 279 项测试在守着那些口径

所有数字都可用仓库里的命令复现，不是截图。

279

后端测试全绿

假客户端 + 内存库，全部离线可复跑

125

接口冒烟用例

对着运行中的真实后端逐个打过去

21

小程序测试用例

展示层纯函数 + 对着真实后端的接口契约

69 + 31

后端模块 + 前端文件

10,409 行 Python、4,666 行 TS/TSX

204KB

前端构建产物

gzip 66KB，ECharts 拆到详情页按需加载

被测试锁住的关键断言（这几条最容易被做坏）

- 改封面、改介绍，不会改变热度与榜单——人工只能碰展示层
- 重算是幂等的：同一份数据算两次，结果完全一致
- 演示数据不得进真实榜单（真实模式下未核验的梗一律挡掉）
- 观测不足时生命周期与赶梗判断必须返回「数据不足」
- 大模型返回的 status 与算法不一致时，以算法为准
- 没有 Key、错误 Key、超时三种情况页面都不崩，且可「重新判断」

AI 不是单点故障（这条也有测试覆盖）

- 未配 Key：文案位显示算法自己写的那句话，标注「文案来源：算法兜底」
- 调用失败 / 超时：返回 unavailable，卡片给「暂时无法生成 + 重新判断」
- 热度、生命周期、图表、B 站数据全部不依赖 AI，照常渲染
- 结果按 (meme_id, kind, data_version) 缓存，数据没变不再打接口
- 429 / 5xx / 超时会重试，但次数有限（默认 2 次，指数退避），绝不无限重试
- API Key 不进前端 bundle、不进日志（有脱敏过滤器）、不进 Git

复现命令：cd backend && python -m pytest | python scripts/smoke_api.py（需后端在跑）

四件我到现在也没解决的事

第 4 条是一个已知的口径偏差，我没修——这是一个取舍，不是疏忽。

脉冲型梗会被误判

琵琶曲 30 天只有 4 天有内容，却播了 3,976 万，规则容易判成过气 → 上榜层用「近 7 天头部播放下限」兜底；后续为脉冲型单独建模

残值会被误判成萌芽

「omg 你吓到了我」近 7 天只剩 3,770 次播放，却落在萌芽期 → 给萌芽期补最低活跃度约束（下一步）

样本量偏小

$n = 31$ 的证伪实验、71 个入池梗，做曲线拟合仍然不宽裕 → 继续每日增量积累；等样本变大后复算全部结论

已知未修的口径偏差

view 是「该日发布 cohort 的累计播放」，老日子多攒了十几天，序列天生向今天下坡，7 天对 7 天的增长率偏高估跌 → 年龄中性的替代量是 search_total（实测上周 789/天 vs 这周 750/天）；改它会重排全部榜单与赶梗结论，2026-09-28 决定先修可信度、暂不动公式

还有两件小事也记在这里：B 站风控下匿名只能取到账号最近约 150~400 条投稿；字幕这一档需要 Cookie，所以「字幕原文摘录」现在可能是空的——那是如实标注。

如果继续做，我会按这个顺序补

顺序不是随意的：先补「能不能信」，再补「准不准」，最后才扩范围。

补可信度

- 把第 4 条口径偏差的替代量（search_total）跑一遍对照，看排名会怎么变
- 把四块空白实验里的观测覆盖率与快照回填做成常规回归测试

补准确度

- 阶段判定混淆矩阵 + 权重消融 + 抽样口径敏感性分析
- 用户实验：20 人对照「看热搜」与「看本系统」的选题表现

扩观测面

- 配 BILI_COOKIE 打通 UP 主空间与字幕轨，把「字幕原文摘录」这一档填满
- 用 search_total 与互动量构造年龄中性指标，替代累计播放口径

扩研究对象

- 从「梗」扩到「梗的类型」：看动作梗、台词梗、形象梗的衰减曲线是否不同
- 在 B 站之外只加一个平台做对照，验证这套口径可迁移

一个我自己最想知道的后续问题：梗的「半衰期」能不能算出来？

现在系统只能回答「它处于哪一段」。如果能对每个梗拟合出一条衰减曲线，就能回答「按历史规律，它还剩几天」——但这就落进了预测，而我在本课题一开始就把「不做未来数值预测」写成了边界。要越过这条线，得先补上足够的样本与一套可验证的评估方式；在那之前，我宁可只报现状。

收尾

梗会凉，但这个账算得清

本课题交出来的不是一个分数，而是一套能被质疑、能被复算的测量方式：

口径写在配置文件里，结论由算法算出，证据带真实 BV 号，算不出来的地方就写「数据不足」。

85

条记录

35

个真实且已核验

20

个上热榜

33

个如实说「数据不足」

请各位老师重点看两处，也欢迎直接拆：

- ① 「数据不足」这个闸门该不该存在——把不知道做成合法输出，是不是一个合格的数据产品该有的态度？
- ② 第 4 条已知未修的口径偏差，我的取舍（先修可信度、暂不动公式）是否合理？

欢迎提问。数据、口径、代码、以及那四块没做完的实验，都可以当场翻。