

赶梗潮 —— B 站网络梗热度与生命周期分析系统

课程：数据科学·开题答辩 | 汇报人： | 学号： | 指导教师：

日期：2026 年 9 月 28 日 | 数据截至：2026-09-27 (真实抓取, 非样例数据)

一、选题背景与研究意义

1.1 一个具体的起点

2026 年 9 月 21 日, B 站账号「梗百科」发布了一期标题为「闪身步是啥梗?」的解说视频, 播放量 64.6 万; 到 9 月 26 日, 这个梗在本系统的自定义热度指数上拿到 **81.0 分**, **位居当日榜首**, 近 7 天相关头部内容播放合计 **1,781 万**。也就是说: 从“有人把它讲明白”到“它火到不能再拖”, 中间只有 5 天。

这 5 天就是本课题要研究的对象。

1.2 问题陈述

现有的热点工具都能回答“此刻什么在前面”, 但回答不了三个更值钱的问题:

- 这个梗**到底有多火** (跨梗可比的量化值, 而不是一个名次);
- 它**走到了生命周期的哪一段** (在冲、在顶、还是在崩);
- 现在**赶这个梗还来不及** (一个可执行的时间判断)。

微博热搜与平台热榜是**存量快照**: 一个梗崩盘当天照样能挂在榜上; 百度指数一类工具度量的是**搜索词**而非梗本身, 「松弛感」这类口语词会混入大量无关检索; 创作者与运营则普遍凭手感判断, 同一个梗每次判断都不一样。

1.3 研究意义

- 理论层面**: 把“网络梗”从文化批评的对象, 变成一个有明确观测口径、可复算、可证伪的时

间序列对象。Lorenz-Spreen 等人（2019）已经证明**集体注意力的半衰期在系统性缩短** [12]，这意味着“还剩多久”正在成为比“有多热”更重要的信息。

- **应用层面**：为内容创作者、品牌社媒运营与一般用户提供“赶梗窗口”判断，减少“跟风即过气”的时间错配。
 - **方法层面**：在真实平台接口存在限流与抽样抖动的前提下，给出一套可审计的数据质量控制方案（见 4.7），这部分是本课题最具数据科学含量的部分。
-

二、国内外研究现状

2.1 模因与网络梗研究

“meme（模因）”由 Dawkins（1976）提出，指依靠**模仿与复制**在文化中扩散的信息单元[1]。Shifman（2012, 2013）把它落到互联网语境，给出“同一梗 = 一组相互模仿的变体”的可操作定义，并把研究问题指向生产、传播与接受三个环节[2][3]。中文世界方面，谢朝群与何自然（2007）系统介绍了语言模因说，区分了基因型与表现型复制[8]；薛一飞（2024）从青年社会心态角度分析了“热梗”的生成动因[9]。

与本课题最接近的是 Bauckhage（2011）：该文用搜索与视频平台的时间序列刻画单个梗的流行曲线，指出流行度分布近似对数正态、且梗的寿命有限[4]；Ward（2025）则把梗放进营销学的 **fad cycle（风潮周期）** 框架，讨论品牌跟风的时机问题[5]——这与本课题的“赶梗判断”是同一个问题，但它没有给出可复算的量化口径。Razza 等（2020）用随机流行病模型描述模因扩散[6]，提供了“为什么会自然归零”的机理视角。

2.2 集体注意力与话题生命周期

Downs（1972）提出的**议题—注意力周期**把公共议题的公众关注分成若干阶段，是“生命周期”这一思路的源头[10]。计算社会科学一侧，Crane 与 Sornette（2008）用亚马逊图书销量证明在线注意力存在**少数几种可复用的脉冲响应形状**[11]；Kleinberg（2002）给出从事件流中检测“突发（burst）”的最优分割方法[13]；Yang 与 Leskovec（2011）把新闻与话题的时间曲线聚成若干响

应类别[14]；Lorenz-Spreen 等（2019）用词典、书名、新闻与推特数据证明**注意力半衰期在加速缩短**[12]。国内情报学界对“网络舆情生命周期”已有较成熟的阶段划分：宋宁、刘婵君（2016）从过程与要素两个视角把突发事件舆情演化归纳为形成期、发展期、消弭期并讨论“关键节点”[15]；史伟等（2022）综述了情感视角下的舆情演化与预测研究[16]。

2.3 流行度量化与预测

Szabo 与 Huberman（2010）在 Digg/YouTube 上证明流行度服从幂律，且**早期增速可预测最终热度**[17]，这是本课题把“增长”作为一等因子的实证依据。视频方向上，Li 等（2013）预测社交网络中视频的流行度[18]，Tan 等（2014）直接研究视频热度的**寿命 (lifetime)** [19]，Li 等（2016）大规模刻画并预测在线视频热度[20]；Zhou 等（2021）系统综述了信息级联分析的模型与方法[21]；Xu 等（2025）在话题标签热度预测中引入大模型推理，但**数值预测仍由统计模型给出、大模型只做辅助**[22]——这与本课题“LLM 不参与计算”的边界设计一致。

2.4 B 站与弹幕的既有研究

Zhang 与 Cassany（2020）以 B 站为对象研究了大规模匿名弹幕的连贯性机制[23]；Wang（2022）分析了弹幕对 B 站社区认同的作用[24]；闫方洁（2017）从媒介文化视角讨论了弹幕经 A 站、B 站引入国内后的“戏仿、拼贴、挪用”式造梗方式[25]；曾一果（2021）分析了弹幕背后青年群体的情感需要[26]。这些工作共同说明：**弹幕/评论是梗的主要载体**，因此本课题把评论与弹幕计入互动与讨论量因子。

2.5 述评：本课题的落点

已有研究	做到了什么	留下的缺口
梗的文化研究[1-6, 8-9, 25-26]	定义、分类、生成机制、社会心态	几乎不给出可复算的时间度量
注意力与生命周期[10-16]	曲线形状可分类、半衰期在缩短、阶段可划分	对象是新闻/议题/搜索词，不是“梗”
流行度预测[17-22]	早期增速可预测、热度寿命可建模	落到单条内容，未做跨创作者的“

已有研究	做到了什么	留下的缺口
		梗”级聚合
B 站平台研究[23-24]	说明弹幕是梗的载体	没有热度指数与赶梗时机的产品化输出

本课题的位置：把上述三条线接成一条可运行链路——用两位解说 UP 主的真实投稿证明”这是个真梗”，用逐日头部内容抽样把它变成时间序列，用五因子指数与规则引擎给出热度、阶段与赶梗判断并把全部口径与数据新鲜度直接显示在产品上。

三、研究内容与关键问题

编号	研究问题	本课题的作答方式
RQ1	一个梗现在有多火？	0-100 自定义热度指数：五因子加权，绝对量先做对数区间归一（见 4.4）
RQ2	它处在生命周期哪一段？	时间序列特征（增长率、距峰值差、连续下滑天数、活跃度）→ 规则引擎 → 六阶段
RQ3	现在赶还来得及吗？	由 RQ1/RQ2 输出经判定规则给出三态（还来得及 / 慎赶 / 你来晚了）+ 置信度 + 理由

明确不做（边界即贡献的一部分）：① 不做未来数值预测，只描述已发生的数据；② 不让大模型修改任何事实或判定，LLM 只把算法结论翻译成成人话，越界表述（“预计”“一定会爆”）直接丢弃；③ 不做多平台与用户体系，先把 B 站这一把尺子做准。

四、技术方案

4.1 数据链路

B 站接口 → 逐日采集 → 清洗与梗匹配 → 日粒度聚合 → 热度指数 → 生命周期判定 → 赶梗判断 → (可选) 大模型解释文案 → FastAPI → React 前端

4.2 发现层：梗从哪里来（本课题的准入设计）

一个梗值不值得被记录，先看有没有人把它讲明白过。选取两个解说账号作为**存在性证明**：梗百科（mid=1544008396，日更）与梗指南（mid=94510621，周更）。做法是翻页拉取二者真实投稿、从标题抽取梗名、以真实 BV 号 + 标题 + 发布时间作为证据入库。

- **准入取并集**：任一账号在 **90 天滚动窗口**内介绍过即入池。实测同一批投稿中，梗百科识别出 37 个梗名、梗指南 22 个，若取交集只剩 **8 个**——日更账号的选题被周更账号的排期一票否决，热度实测最高的「闪身步」（81.0）当时就在库外。改为并集后入池 **51 个**，覆盖率提升 6.4 倍。
- **认证降级为标签**：两位都做过的仍单独标「双 UP 认证」，只有一位做过的写明是哪一位，可信度信息不损失，但不再作为闸门。
- **认证窗口 ≠ 报告窗口**：解说视频通常比梗的爆发期早 1~2 周，两窗合一曾把 8 月 21 日解说的「老叟戏顽童」整条排除（该梗 9 月仍居热榜）。
- **写法合并**：同一梗在两个账号标题里写法不同时（“胆子肥嘟嘟” / “胆子肥嘟嘟的”）按**互相包含**这一保守条件合并；仅“长得像”的名称（宗主第一招 / 宗主第二招）绝不自动合并。
- **占位名拒收**：UP 主为规避敏感词把标题写成「XX 在哪？最优骑士小碎步」「你会 XXX 吗」，这类名字无法用于检索，在抽取阶段直接丢弃（实测 51 条里有 6 条）。

4.3 观测与清洗：把”相关视频”筛出来

对每个梗、每一天，用 `pubtime_begin_s/pubtime_end_s` 区间查询 + `order=click` 取当日**播放量最高的 20 条**相关视频作为样本。相关性由加权证据打分： $0.6 \times \text{标题命中} + 0.2 \times \text{简介命中} + 0.2 \times \text{标签命中}$ ，阈值 0.5。

短别名只算弱证据（中文 2~3 字别名基本是常用词）：早期把「我不是黄豆」的别名写成“黄豆”，导致 418 条样本里 343 条其实只在讲黄豆（琵琶曲黄豆版、炒黄豆、树叶做豆腐），该梗还挂着榜首。现规则为：短于 4 字的别名必须再有第二个词佐证才能过阈值。本轮并集入库共剔除不相关样本 **1,250 条**。

4.4 热度指数（RQ1）

$\text{Hotness} = 0.25 \cdot \text{增长} + 0.25 \cdot \text{播放} + 0.20 \cdot \text{互动} + 0.16 \cdot \text{内容} + 0.14 \cdot \text{创作者}$

- 每个因子先做**对数区间归一化**：播放量差三个量级的梗必须能同框比较，线性归一会让亿级老梗永远压住新梗。
- **增长权重给到 0.25**，只看最近 7 天相对前 7 天，避免“去年 1 亿播放、今天没人做”的梗霸榜。
- **样本不足不外推**：前一周讨论量 < 30 或样本视频 < 3 条时，增长率置空并对整体打折，卡片上显示“—”而不是 +585% 这种噪声。

4.5 生命周期与赶梗判断（RQ2、RQ3）

六阶段：萌芽 → 上升 → 爆发 → 平稳 → 退潮 → 过气，规则自上而下匹配，判定依据（增长率、距峰值差、连续下滑天数、活跃度）随结果一起输出到详情页。赶梗判断输出三态 + 置信度 + 一句算法自己的理由；大模型只能复述该结论，与其不一致时以算法为准。

4.6 热榜门槛：准入 ≠ 上榜

首页要回答“今天玩什么”，所以梗还得**活着**：

$\text{热榜} = \text{通过发现层准入} \wedge \text{有指标快照} \wedge \text{阶段非“过气”} \wedge \text{近 7 天头部播放} \geq 1 \text{ 万}$

刻意**不用**“有内容天数”当门槛：「琵琶曲」30 天只有 4 天有内容，但那几天播了 3,976 万，按天数卡会误杀脉冲型梗。实测该门槛把热榜从 31 个条目收敛到 **12 个**，被挡掉的 19 个中 17 个为过气 2 个近 7 天播放不足 1 万（如「omg 你吓到我了」30 天里 26 天有内容但近 7 天仅 3,770 次播放，属历史残值）。梗库接口（scope=all）不受影响，被挡掉的梗仍可查。

4.7 数据质量控制（本课题最难的部分）

问题	现象（实测）	处理
假增长	一次抓完再摊到每天，算出 +23,616% 的增长	逐日带时间区间查询，只统计当天发布内容
抽样抖动 刷薄数据	同一个词同一天两次返回的头部 20 条差异极大：琵琶曲 4 天/3,976 万 → 1 天/18 条，热度 44.2 → 0.0	同一天只保留更好的一次观测（比较样本数与播放量，绝不相加），并提供从快照按同一规则回填的工具（本轮回填 53 天）
空窗误删	一次采空就把历史真实数据清掉	空窗只清非本源（演示）数据，同源旧快照保留并计数
新鲜度不可见	用户以为数据是“现在的”	接口给出 data_through 与滞后天数，界面写明“统计窗口不含今天”
演示数据冒充真实	手写梗库与真梗同榜	演示数据强制标注，且真实模式下无在线核验证据者不进榜

五、数据来源与规模（全部真实抓取）

指标	数值	说明
梗库条目	84	其中 83 个通过发现层准入，44 个为双 UP 认证
真实 B 站来源的梗	55	其余为演示梗库（用于跑通流程，界面明确标注）
认证证据记录	127 条	其中 53 条为真实投稿证据（含可点开的 BV 号）
日粒度统计	2,010 行	其中 447 行“当日有内容”
采信视频样本	1,632 条	每条都带相关性得分与命中词，可抽查
头部样本累计播放	2.08 亿	每日头部 20 条相关视频的合计，非全站绝对量

指标	数值	说明
有指标快照的梗	67	其余 17 个入池但窗口内未采到内容
当前热榜	12	过气与残值梗已被门槛挡掉（见 4.6）
统计截至	2026-09-27 滞后 1 天，窗口刻意不含当天	
采集接口：B 站 <code>wbi/search/type</code> （逐日区间）、 <code>web-interface/view</code> （点赞/投币/收藏）、 <code>space/wbi/arc/search</code> （UP 主投稿，匿名 + WBI 签名下按会话强风控，412/-352 需退避重试）。 全库一轮采集 51 个梗约 30~45 分钟。		

六、可行性分析与已完成工作

- **系统已可运行**：后端 61 个 Python 模块约 7,900 行，前端 29 个 TS/TSX 文件约 4,000 行，测试 17 个文件约 2,660 行；一键启动脚本、CLI 采集/重算入口均已就绪。
- **质量验证已完成**：单元与集成测试 **169 项全部通过**；对真实数据后端的接口冒烟 **70 项全部通过**（含“改元数据不影响热度与榜单”“重算幂等”“演示数据不得进真实榜单”等关键断言）。
- **数据可得性已验证**：接口可达性、限流边界、图床 Referer 规则等均为实测结论，非假设。
- **一个已完成的证伪实验**（可作为答辩现场展示）：把“解说视频破百万才值得做”这一直觉放到 31 个上榜梗上检验，得 Pearson $r = +0.40$ ($p = 0.028$)、Spearman $\rho = +0.29$ ($p = 0.12$ ，不显著)，即解说播放量只能解释热度方差的约 **16%**；反例同时存在——解说 64.6 万的「闪身步」热度 81.0 居首，解说 160.7 万的「宗主第二招」热度 0.0。结论：该指标可用于**采集成本预算**，不可作为准入判据。

七、创新点

1. **对象创新**：把“梗”从单条内容提升为**跨创作者聚合的时间序列实体**，并给出可复算的热度口

径。

- 2. **准入创新**：以两位解说 UP 主的真实投稿作为梗的**存在性证明**，用 90 天滚动的并集准入替代交集闸门，同时把“双 UP 认证”降级为可信度标签——覆盖率提升 6.4 倍而不损失可审计性（每条证据都是真 BV 号）。
- 3. **输出创新**：不止报热度，而是输出**带置信度的赶梗时机判断**，并把抽样口径、统计滞后、认证强度全部直接显示在产品上，使结论可被质疑与复算。

八、局限与风险

局限	具体表现	应对方案
脉冲型梗的阶段误判	琵琶曲 30 天仅 4 天有内容却播了 3,976 万，规则易判为过气	上榜层已用播放量下限兜底；后续为脉冲型单独建模
残值误判	「omg 你吓到我了」近 7 天仅 3,770 播放却判为“萌芽期”	萌芽期增加最低活跃度约束（已列入下一步）
平台风控	匿名只能稳定取到账号最近约 50 条投稿，热搜/热门接口给空壳	换指纹退避重试 + 索引缓存 + 缺口如实报告；可选 Cookie 增强
抽样口径限制	每日头部 20 条是“头部内容合计”，不是全站绝对播放	界面与论文中明确口径，只做同尺子的相对比较
伦理与合规	采集公开接口数据、展示公开视频信息与封面	只取公开元数据、不外存图片、遵守 robots 与频控，产品标注数据源

九、进度安排

时间	工作内容	交付物
第 1-2 周	上榜层口径重做（过气不出榜已完成，脉冲型单独处理）、阶段规则补最低活跃度约束	口径说明 + 回归测试
第 3 周	增量刷新与调度；对 17 个采空梗用别名兜底再采一轮	每日自动更新的数据集
第 4 周	用户实验：20 人对照“看热搜”与“看本系统”的选题准确率与主观有用性	实验数据与分析
第 5 周	一致性检验：阶段判定混淆矩阵、热度与人工标注的 Spearman 相关、门槛消融实验	图表与结论
第 6 周	撰写论文、整理代码与可复现说明	论文 + 源码 + 数据集

十、预期成果

1. 一个可运行的 B 站梗热度与生命周期分析系统（Web 端 + CLI + 后端 API）；
2. 一份可复现的真实数据集（梗库、日粒度统计、认证证据、采集与清洗脚本）；
3. 一套关于“梗级热度指数 + 阶段判定 + 赶梗时机”的评估报告（含混淆矩阵、相关性与消融实验）；
4. 学位论文（技术报告）一篇。

参考文献

说明：以下条目均已核验（Crossref DOI 解析 / CNKI 期刊门户 / 期刊官网元数据 / 论文原文）。

完整核验记录与 DOI 见 <docs/research/related-literature.md>。

- [1] DAWKINS R. The Selfish Gene[M]. Oxford: Oxford University Press, 1976. [2] SHIFMAN L. An anatomy of a YouTube meme[J]. New Media & Society, 2012, 14(2): 187-203. [3] SHIFMAN L. Memes in Digital Culture[M]. Cambridge: MIT Press, 2013. [4] BAUCKHAGE C. Insights into Internet Memes[C]// Proceedings of the International AAAI Conference on Web and Social Media, 2011, 5(1): 42-49. [5] WARD M R. Internet Meme Marketing over the Fad Cycle[J]. Journal of Interactive Marketing, 2026, 61(1): 25-40. [6] RAZA A, RAFIQ M, BALEANU D, et al. Numerical simulations for stochastic meme epidemic model[J]. Advances in Difference Equations, 2020, 2020(1). [7] ZHOU F, XU X, TRAJCEVSKI G, et al. A survey of information cascade analysis: models, foundations and applications[J]. ACM Computing Surveys, 2021, 54(2): 1-36. [8] 谢朝群, 何自然. 语言模因说略[J]. 现代外语, 2007(1): 30-39. [9] 薛一飞. 网络热梗背后的青年群体社会心态探析[J]. 人民论坛, 2024(10 下期). [10] DOWNS A. Up and down with ecology: the “issue-attention cycle” [J]. The Public Interest, 1972(28): 38-50. [11] CRANE R, SORNETTE D. Robust dynamic classes revealed by measuring the response function of a social system[J]. PNAS, 2008, 105(41): 15649-15653. [12] LORENZ-SPREEN P, MØNSTED B M, HÖVEL P, LEHMANN S. Accelerating dynamics of collective attention[J]. Nature Communications, 2019, 10(1). [13] KLEINBERG J. Bursty and hierarchical structure in streams[C]// KDD 2002: 91-101. [14] YANG J, LESKOVEC J. Patterns of temporal variation in online media[C]// WSDM 2011: 177-186. [15] 宋宁, 刘婵君. 过程与要素视角下的突发事件网络舆情演化规律研究综述[J]. 图书情报工作, 2016, 60(15). [16] 史伟, 薛广聪, 何绍义. 情感视角下的网络舆情研究综述[J]. 图书情报知识, 2022(1): 105-117. [17] SZABO G, HUBERMAN B A. Predicting the popularity of online content[J]. Communications of the ACM, 2010, 53(8): 80-88. [18] LI H, MA X, WANG F, et al. On popularity prediction of videos shared in online social networks[C]// CIKM 2013: 169-178. [19] TAN Z, ZHANG Y, LI C, LIU N. Lifetime popularity prediction for online videos[C]// BMSB 2014: 1-6. [20] LI C, LIU J, OUYANG S. Characterizing

and predicting the popularity of online videos[J]. IEEE Access, 2016, 4: 1630-1641. [21] JENDERS M, KASNECI G, NAUMANN F. Analyzing and predicting viral tweets[C]// WWW 2013 Companion: 657-664. [22] XU Y, WU J, WAN H, et al. Forecasting the buzz: enriching hashtag popularity prediction with LLM reasoning[C]// CIKM 2025: 5396-5400. [23] ZHANG L T, CASSANY D. Making sense of danmu: coherence in massive anonymous chats on Bilibili.com[J]. Discourse Studies, 2020, 22(4): 483-502. [24] WANG R. Community-building on Bilibili: the social impact of danmu comments[J]. Media and Communication, 2022, 10(2): 54-65. [25] 闫方洁. 媒介文化研究视角下“弹幕”的生成机制及其亚文化意义[J]. 思想理论教育, 2017(10): 81-85. [26] 曾一果. 弹幕背后青年群体的情感需要与价值诉求[J]. 人民论坛, 2021(4 上期). [27] LIN C X, ZHAO B, MEI Q, HAN J. PET: a statistical model for popular events tracking in social contexts[C]// KDD 2010: 929-938. [28] 沈婕, 等. 网络舆情态势及情感多维特征分析与可视化——以 COVID-19 疫情为例[J]. 地球信息科学学报, 2021, 23(2): 318-330. [29] 汪明, 等. 基于改进 SEIQR 模型的网络舆情传播建模与仿真研究[J]. 知识管理论坛, 2026, 11(4): 381-399.